

Нелинейные классификаторы. Калибровка вероятностей

Елена Кантонистова

ПЛАН

- Ядровой метод опорных векторов
- Простые нелинейные классификаторы
- Калибровка вероятностей

НАИВНЫЙ БАЙЕСОВСКИЙ КЛАССИФИКАТОР

НАИВНЫЙ БАЙЕСОВСКИЙ КЛАССИФИКАТОР

Наивный байесовский классификатор — это алгоритм классификации, основанный на теореме Байеса с допущением о независимости признаков.

Пример: фрукт может считаться яблоком, если:

- 1) он красный
- 2) круглый
- 3) его диаметр составляет порядка 8 см




Предполагаем, что признаки вносят независимый вклад в вероятность того, что фрукт является яблоком.

ТЕОРЕМА БАЙЕСА

Теорема Байеса:

$$P(c|x) = \frac{P(x|c) \cdot P(c)}{P(x)}$$

- $P(c|x)$ - вероятность того, что объект со значением признака x принадлежит классу c .
- $P(c)$ – априорная вероятность класса c .
- $P(x|c)$ - вероятность того, что значение признака равно x при условии, что объект принадлежит классу c .
- $P(x)$ – априорная вероятность значения признака x .



ПРИМЕР РАБОТЫ БАЙЕСОВСКОГО АЛГОРИТМА

Пример: на основе данных о погодных условиях необходимо определить, состоится ли матч.

- Преобразуем набор данных в следующую таблицу:

Weather	No	Yes
Overcast	0	4
Rainy	3	2
Sunny	2	3
Grand Total	5	9

Weather	Play
Sunny	No
Overcast	Yes
Rainy	Yes
Sunny	Yes
Sunny	Yes
Overcast	Yes
Rainy	No
Rainy	No
Sunny	Yes
Rainy	Yes
Sunny	No
Overcast	Yes
Overcast	Yes
Rainy	No

ПРИМЕР РАБОТЫ БАЙЕСОВСКОГО АЛГОРИТМА

Решим задачу с помощью теоремы Байеса:

$$P(Yes|Sunny) = P(Sunny|Yes) \cdot P(Yes)/P(Sunny)$$

Таблица частот				
Weather	No	Yes		
Overcast	0	4	=4/14	0.29
Rainy	3	2	=5/14	0.36
Sunny	2	3	=5/14	0.36
Grand Total	5	9		
	=5/14	=9/14		
	0.36	0.64		

- $P(Sunny|Yes) = \frac{3}{9}, P(Sunny) = \frac{5}{14}, P(Yes) = \frac{9}{14}.$
- $P(Yes|Sunny) = \frac{3}{9} \cdot \frac{9}{14} \div \frac{5}{14} = \frac{3}{5} = 0,6 \Rightarrow 60\%.$

В СЛУЧАЕ НЕСКОЛЬКИХ ПРИЗНАКОВ

Пусть $x_1, \dots, x_n$ - признаки объекта, y — целевая переменная.

Тогда теорема Байеса записывается в виде

$$P(y|x_1, \dots, x_n) = \frac{P(x_1|y)P(x_2|y) \dots P(x_n|y)P(y)}{P(x_1)P(x_2) \dots P(x_n)}.$$

Вероятности в правой части формулы вычисляются с помощью частотных таблиц, как и в одномерном случае.

[почитать статью про Байесовский классификатор](#)

БАЙЕСОВСКИЙ АЛГОРИТМ ДЛЯ КЛАССИФИКАЦИИ

Плюсы и минусы:

- + классификация быстрая и простая
- + в случае, если выполняется предположение о независимости, классификатор показывает очень высокое качество
- если в тестовых данных присутствует категория, не встречавшаяся в данных для обучения, модель присвоит ей нулевую вероятность


НАИВНЫЙ БАЙЕСОВСКИЙ АЛГОРИТМ

https://scikit-learn.org/stable/modules/naive_bayes.html


МЕТОД БЛИЖАЙШИХ СОСЕДЕЙ

МЕТОД БЛИЖАЙШИХ СОСЕДЕЙ

Идея: схожие объекты находятся близко друг к другу в пространстве признаков.



Как классифицировать новый объект?



МЕТОД БЛИЖАЙШИХ СОСЕДЕЙ


Чтобы классифицировать новый объект, нужно:

- Вычислить расстояние до каждого из объектов обучающей выборки.
- Выбрать k объектов обучающей выборки, расстояние до которых минимально.
- Класс классифицируемого объекта — это класс, наиболее часто встречающийся среди k ближайших соседей.

МЕТОД БЛИЖАЙШИХ СОСЕДЕЙ

Число ближайших соседей k – гиперпараметр метода.

Например, для $k = 4$ получим:



То есть объект будет отнесён к классу *треугольников*.

ФОРМАЛИЗАЦИЯ МЕТОДА

Пусть k — количество соседей. Для каждого объекта u возьмём k ближайших к нему объектов из тренировочной выборки:

$$x_{(1;u)}, x_{(2;u)}, \dots, x_{(k;u)}.$$

Тогда класс объекта u определяется следующим образом:

$$a(u) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^k [y(x_{(i;u)}) = y]$$

ФОРМАЛИЗАЦИЯ МЕТОДА

Пусть k — количество соседей. Для каждого объекта u возьмём k ближайших к нему объектов из тренировочной выборки:

$$x_{(1;u)}, x_{(2;u)}, \dots, x_{(k;u)}.$$

Тогда класс объекта u определяется следующим образом:

$$a(u) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^k [y(x_{(i;u)}) = y]$$

Ближайшие объекты — это объекты, расстояние от которых до данного объекта наименьшее по некоторой метрике ρ .

ФОРМАЛИЗАЦИЯ МЕТОДА

Пусть k — количество соседей. Для каждого объекта u возьмём k ближайших к нему объектов из тренировочной выборки:

$$x_{(1;u)}, x_{(2;u)}, \dots, x_{(k;u)}.$$

Тогда класс объекта u определяется следующим образом:

$$a(u) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^k [y(x_{(i;u)}) = y]$$


Ближайшие объекты — это объекты, расстояние от которых до данного объекта наименьшее по некоторой метрике ρ .

- В качестве метрики ρ как правило используют **евклидово расстояние, но можно использовать и другие метрики**.
- **Перед использованием метода необходимо масштабировать данные**, иначе признаки с большими числовыми значениями будут доминировать при вычислении расстояний.

ЯДРОВОЙ МЕТОД ОПОРНЫХ ВЕКТОРОВ

МЕТОД ОПОРНЫХ ВЕКТОРОВ: РАЗДЕЛИМЫЙ СЛУЧАЙ

Цель метода опорных векторов (Support Vector Machine) – максимизировать ширину разделяющей полосы.



МЕТОД ОПОРНЫХ ВЕКТОРОВ: РАЗДЕЛИМЫЙ СЛУЧАЙ

- $a(x) = \text{sign}((w, x) + w_0)$
- Нормируем параметры w и w_0 так, что

$$\min_{x \in X} |(w, x) + w_0| = 1$$

МЕТОД ОПОРНЫХ ВЕКТОРОВ: РАЗДЕЛИМЫЙ СЛУЧАЙ


- $a(x) = \text{sign}((w, x) + w_0)$
- Нормируем параметры w и w_0 так, что

$$\min_{x \in X} |(w, x) + w_0| = 1$$

Расстояние от точки x_0 до разделяющей гиперплоскости,
задаваемой

классификатором:

$$\rho(x_0, a) = \frac{|(w, x_0) + w_0|}{||w||}$$



МЕТОД ОПОРНЫХ ВЕКТОРОВ: РАЗДЕЛИМЫЙ СЛУЧАЙ

- Нормируем параметры w и w_0 так, что

$$\min_{x \in X} |(w, x) + w_0| = 1$$


Тогда расстояние от точки x_0 до разделяющей гиперплоскости, задаваемой классификатором:

$$\rho(x_0, a) = \frac{|(w, x_0) + w_0|}{||w||}$$

- Расстояние до ближайшего объекта $x \in X$:

$$\min_{x \in X} \frac{|(w, x) + w_0|}{||w||} = \frac{1}{||w||} \min_{x \in X} |(w, x) + w_0| = \frac{1}{||w||}$$


РАЗДЕЛЯЮЩАЯ ПОЛОСА



ЛИНЕЙНО НЕРАЗДЕЛИМАЯ ВЫБОРКА

- Существует хотя бы один объект $x \in X$, что

$$y_i((w, x_i) + w_0) < 1$$



ЯДРОВОЙ МЕТОД ОПОРНЫХ ВЕКТОРОВ

Пусть исходная выборка (с признаками $x_1, x_2, \dots, x_n$) *линейно не разделима*.


Может существовать такое преобразование координат

$$(y_1, y_2, \dots, y_N) = f(x_1, x_2, \dots, x_n).$$

что в пространстве новых



координат выборка становится

линейно разделимой.




- ***Применение преобразования координат и метода главных компонент называется ядровым методом главных компонент (kernel SVM).***

РАДИАЛЬНОЕ ЯДРО




ПОЛИНОМИАЛЬНОЕ ЯДРО

*1-Dimensional Linearly
Inseparable Classes*




*1-Dimensional Linearly
Inseparable Classes transformed with
Polynomial Kernel of Degree 2*




РАЗДЕЛЯЮЩИЕ ПОВЕРХНОСТИ SVM ДЛЯ РАЗЛИЧНЫХ ЯДЕР


SVC with linear kernel




SVC with RBF kernel



SVC with polynomial (degree 3) kernel



LinearSVC (linear kernel)



КАЛИБРОВКА ВЕРОЯТНОСТЕЙ

КАЛИБРОВКА ВЕРОЯТНОСТЕЙ

Калибровка вероятностей - приведение ответов алгоритма к значениям, близким к вероятностям объектов принадлежать конкретному классу.

Зачем это нужно?

- Вероятности гораздо проще интерпретировать
- Вероятности могут дать дополнительную информацию о результатах работы алгоритма

КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса, $Y = \{+1, -1\}$

Задача: для классификатора $a(x)$, предсказывающего значения из отрезка $[0, 1]$, либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями $p(y = +1|x)$.


КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса, $Y = \{+1, -1\}$

Задача: для классификатора $a(x)$, предсказывающего значения из отрезка $[0, 1]$, либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями $p(y = +1|x)$.

Идея: обучаем логистическую регрессию на ответах классификатора $a(x)$.

ПРИМЕР ИЗ SKLEARN



КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса, $Y = \{+1, -1\}$

Задача: для классификатора $a(x)$, предсказывающего значения из отрезка $[0, 1]$, либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями $p(y = +1|x)$.

Идея: *обучаем логистическую регрессию на ответах классификатора $a(x)$.*

КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса, $Y = \{+1, -1\}$

Задача: для классификатора $a(x)$, предсказывающего значения из отрезка $[0, 1]$, либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями $p(y = +1|x)$.

Идея: *обучаем логистическую регрессию на ответах классификатора $a(x)$.*

- $$\pi(x; \alpha; \beta) = \sigma(\alpha \cdot a(x) + \beta) = \frac{1}{1 + e^{-(\alpha \cdot a(x) + \beta)}}$$

Изотоническая регрессия

Изотоническая регрессия — это способ исправить вероятности модели, не нарушая их порядок.


Ключевая идея:

Если модель дала объекту A вероятность выше, чем объекту B , то после калибровки так и должно остаться.

То есть функция калибровки должна быть монотонно неубывающей.

Reliability Diagram

- Разбиваем объекты на бины по предсказанной вероятности – объединяем точки из бина в одну
- Для точек из каждого бина считаем эмпирическую вероятность и строим диаграмму



Изотоническая регрессия

Изотоническая регрессия — это поиск функции f , которая:

$$\min_f \sum_{i=1}^n (y_i - f(s_i))^2$$

при ограничении:


$$s_i \leq s_j \Rightarrow f(s_i) \leq f(s_j)$$

где:

- s_i — скор (предсказание модели),
- $y_i \in \{0, 1\}$ — истинный класс,
- $f(s)$ — откалиброванная вероятность.

Изотоническая регрессия

Изотоническая регрессия должна так откалибровать прогнозы, чтобы, условно, reliability diagram стала монотонно возрастающей.




Изотоническая регрессия

Алгоритм PAVA:

- Идем по упорядоченному по возрастанию набору вероятностей
- В случае убывания следующего предсказания (по оси empirical probability) пересчитываем “вероятности” с сохранением монотонности

<https://josephsalmon.eu/blog/isotonic/>

РАЗЛИЧНЫЕ КАЛИБРОВКИ



Как посчитать качество предсказанных вероятностей?

Brier score — это метрика для оценки качества предсказанных вероятностей в бинарной классификации.

Она измеряет, насколько близко предсказанная вероятность к реальному исходу.

$$\text{BS} = \frac{1}{N} \sum_{i=1}^N (f_i - y_i)^2$$

где:

- N — число объектов,
- $f_i \in [0, 1]$ — предсказанная вероятность для объекта i ,
- $y_i \in \{0, 1\}$ — истинная метка класса.

Обучение калибровочных моделей

Testing set		Training set	
Training set	Testing set	Training set	
Training set		Testing set	Training set
	Training set		Testing set

